

Concavidad y Optimización

Continuación ejemplos y Lagrangiana

Abelardo Jordán Liza

Maestría en Matemáticas Aplicadas
PUCP

Setiembre 28, 2023

Un problema básico de clasificación

Supongamos $k + m$ pacientes que recibieron un tratamiento especial, de modo que se les ha evaluado en n características de desempeño (post tratamiento). Sean

$$\begin{aligned} A &= \{a^1, \dots, a^k\} \subset \mathbb{R}^n && \text{en } k \text{ pacientes el tratamiento fue efectivo} \\ B &= \{b^1, \dots, b^m\} \subset \mathbb{R}^n && \text{en } m \text{ pacientes no respondió el tratamiento} \end{aligned}$$

Objetivo: Encontrar un clasificador escalar de las clases A y B . Podemos pensar en una función $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$\varphi(\mathbf{a}^i) > 0 \text{ para } i = 1, \dots, k \quad \text{y} \quad \varphi(\mathbf{b}^j) < 0 \text{ para } j = 1, \dots, m.$$

Un problema básico de clasificación

Supongamos $k + m$ pacientes que recibieron un tratamiento especial, de modo que se les ha evaluado en n características de desempeño (post tratamiento). Sean

$$\begin{aligned} A &= \{a^1, \dots, a^k\} \subset \mathbb{R}^n && \text{en } k \text{ pacientes el tratamiento fue efectivo} \\ B &= \{b^1, \dots, b^m\} \subset \mathbb{R}^n && \text{en } m \text{ pacientes no respondió el tratamiento} \end{aligned}$$

Objetivo: Encontrar un clasificador escalar de las clases A y B . Podemos pensar en una función $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$\varphi(\mathbf{a}^i) > 0 \text{ para } i = 1, \dots, k \quad \text{y} \quad \varphi(\mathbf{b}^j) < 0 \text{ para } j = 1, \dots, m.$$

Classificador lineal afín

$$\varphi(x) = v'x - \alpha$$

Se requiere conocer v y α .

Un problema básico de clasificación

Supongamos $k + m$ pacientes que recibieron un tratamiento especial, de modo que se les ha evaluado en n características de desempeño (post tratamiento). Sean

$$\begin{aligned} A &= \{a^1, \dots, a^k\} \subset \mathbb{R}^n && \text{en } k \text{ pacientes el tratamiento fue efectivo} \\ B &= \{b^1, \dots, b^m\} \subset \mathbb{R}^n && \text{en } m \text{ pacientes no respondió el tratamiento} \end{aligned}$$

Objetivo: Encontrar un clasificador escalar de las clases A y B . Podemos pensar en una función $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$\varphi(\mathbf{a}^i) > 0 \text{ para } i = 1, \dots, k \quad \text{y} \quad \varphi(\mathbf{b}^j) < 0 \text{ para } j = 1, \dots, m.$$

Classificador lineal afín

$$\varphi(x) = v'x - \alpha$$

Se requiere conocer v y α .

¿Cuál es el criterio para un “mejor” clasificador?

Un problema básico de clasificación

Supongamos $k + m$ pacientes que recibieron un tratamiento especial, de modo que se les ha evaluado en n características de desempeño (post tratamiento).

Sean

$$\begin{array}{ll} A = \{a^1, \dots, a^k\} \subset \mathbb{R}^n & \text{en } k \text{ pacientes el tratamiento fue efectivo} \\ B = \{b^1, \dots, b^m\} \subset \mathbb{R}^n & \text{en } m \text{ pacientes no respondió el tratamiento} \end{array}$$

Objetivo: Encontrar un clasificador escalar de las clases A y B . Podemos pensar en una función $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$\varphi(a^i) > 0 \text{ para } i = 1, \dots, k \quad \text{y} \quad \varphi(b^j) < 0 \text{ para } j = 1, \dots, m.$$


Classificador lineal afín

$$\varphi(x) = v'x - \alpha$$

Se requiere conocer v y α .

¿Cuál es el criterio para un “mejor” clasificador?

¿Esto implica condiciones que involucran a v y α ?



- Considerando las calificaciones que otorga φ tanto a los a^i como a los b^j .

Se definen los correspondientes errores:

$$e_-(a^i) := \begin{cases} 0 & \text{si } \varphi(a^i) \geq 0 \\ \alpha - v' a^i & \text{si } \varphi(a^i) < 0 \end{cases} \quad \text{y} \quad e_+(b^j) := \begin{cases} 0 & \text{si } \varphi(b^j) \leq 0 \\ v' b^j - \alpha & \text{si } \varphi(b^j) > 0 \end{cases}$$

Podemos formular el problema de optimización

$$\min_{v, \alpha} \sum_{i=1}^k e_-(a^i) + \sum_{j=1}^m e_+(b^j) \quad \left(e_-(a^i) = \max\{0, -\varphi(a^i)\} \right) \quad (1)$$

Note que la función objetivo es no-negativa y lineal por partes. Además, para $v = 0$ y $\alpha = 0$, ésta es idénticamente nula para los a^i y los b^j y así la función objetivo resulta nula y φ no sería útil. Podemos asumir que $v \neq 0$ y agregar la restricción $\|v\| = 1$ al problema no-lineal (1)

- Considerando las calificaciones que otorga φ tanto a los a^i como a los b^j . Se definen los correspondientes errores:

$$e_-(a^i) := \begin{cases} 0 & \text{si } \varphi(a^i) \geq 0 \\ \alpha - v'a^i & \text{si } \varphi(a^i) < 0 \end{cases} \quad \text{y} \quad e_+(b^j) := \begin{cases} 0 & \text{si } \varphi(b^j) \leq 0 \\ v'b^j - \alpha & \text{si } \varphi(b^j) > 0 \end{cases}$$

Podemos formular el problema de optimizaci3n

$$\min_{v, \alpha} \sum_{i=1}^k e_-(a^i) + \sum_{j=1}^m e_+(b^j) \quad \left(e_-(a^i) = \max\{0, -\varphi(a^i)\} \right) \quad (1)$$

Note que la funci3n objetivo es no-negativa y lineal por partes. Adem3s, para $v = 0$ y $\alpha = 0$, 3sta es identicamente nula para los a^i y los b^j y as3 la funci3n objetivo resulta nula y φ no ser3a 3til. Podemos asumir que $v \neq 0$ y agregar la restricci3n $\|v\| = 1$ al problema no-lineal (1)

Hacemos las asignaciones $s_i = e_-(a^i)$ y $z_j = e_+(b^j)$, reformulamos el problema (1) por el problema

$$\begin{aligned} \min_{v, \alpha, s, z} \quad & \sum_{i=1}^k s_i + \sum_{j=1}^m z_j \\ \text{s.a.} \quad & v'a^i - \alpha + s_i \geq 0 \quad i = 1, \dots, k. \\ & v'b^j - \alpha + z_j \leq 0 \quad j = 1, \dots, m. \\ & s \geq 0, z \geq 0 \\ & v'v = 1 \end{aligned} \quad (2)$$

Otra manera de empoderar al discriminador(eliminando la restricción sobre $\|v\|$), es crear una zona de amortiguamiento entre los conjuntos A y B , esto se concretiza modificando las restricciones lineales de desigualdad:

$$\begin{aligned}v' a^i - \alpha + s_i &\geq 1, & i = 1, \dots, k. \\v' b^j - \alpha + z_j &\leq -1, & j = 1, \dots, m.\end{aligned}$$

y para prever que $\|v\|$ no sea bastante grande (caso contrario la zona de amortiguamiento resultaría muy pequeña), agregamos un término en la función objetivo que permita controlar a $\|v\|$.

Otra manera de empoderar al discriminador(eliminando la restricción sobre $\|v\|$), es crear una zona de amortiguamiento entre los conjuntos A y B , esto se concretiza modificando las restricciones lineales de desigualdad:

$$\begin{aligned} v'a^i - \alpha + s_i &\geq 1, & i = 1, \dots, k. \\ v'b^j - \alpha + z_j &\leq -1, & j = 1, \dots, m. \end{aligned}$$

y para prever que $\|v\|$ no sea bastante grande (caso contrario la zona de amortiguamiento resultaría muy pequeña), agregamos un término en la función objetivo que permita controlar a $\|v\|$.

Generamos el problema, con $\delta > 0$ dado:

$$\begin{aligned} \min_{v, \alpha, s, z} \quad & \sum_{i=1}^k s_i + \sum_{j=1}^m z_j + \delta \|v\|^2 \\ \text{s.a.} \quad & v'a^i - \alpha + s_i \geq 1, & i = 1, \dots, k. \\ & v'b^j - \alpha + z_j \leq -1, & j = 1, \dots, m. \\ & s \geq 0, z \geq 0 \end{aligned} \tag{3}$$

Sean f, g_i, h_j funciones definidas en \mathbb{R}^n y C un conjunto cerrado de \mathbb{R}^n . Para el problema

$$\begin{array}{ll} \text{mín} & f(x) \\ (ProMix) & \text{s.a. } g_i(x) \leq 0, \ i = 1, \dots, m. \\ & h_j(x) = 0, \ j = 1, \dots, p. \\ & x \in C \end{array} \quad (4)$$

definimos la función Lagrangiana

$$L(x, \lambda, \mu) := f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x) \quad (5)$$

con $x \in C, (\lambda, \mu) \in \mathbb{R}_+^m \times \mathbb{R}^p =: \Lambda_0$.

Condición necesaria de optimalidad: Recuerde que si $\hat{x} \in C$ resuelve el problema (asumiendo diferenciabilidad de las funciones involucradas), entonces la condición necesaria para el (ProMix) puede expresarse como

$$-\nabla_x L(\hat{x}, \lambda, \mu) \in N_C(\hat{x}).$$

Condición necesaria de optimalidad: Recuerde que si $\hat{x} \in C$ resuelve el problema (asumiendo diferenciabilidad de las funciones involucradas), entonces la condición necesaria para el (ProMix) puede expresarse como

$$-\nabla_x L(\hat{x}, \lambda, \mu) \in N_C(\hat{x}).$$

Condición suficiente de optimalidad: Si C es convexo cerrado, f, g_i convexas y h_j afines lineales, entonces si existen $\hat{x} \in C$, $(\hat{\lambda}, \hat{\mu}) \in \Lambda_0$, que satisfacen las condiciones KKT, se sigue que \hat{x} resuelve (Promix).

Condición necesaria de optimalidad: Recuerde que si $\hat{x} \in C$ resuelve el problema (asumiendo diferenciabilidad de las funciones involucradas), entonces la condición necesaria para el (ProMix) puede expresarse como

$$-\nabla_x L(\hat{x}, \lambda, \mu) \in N_C(\hat{x}).$$

Condición suficiente de optimalidad: Si C es convexo cerrado, f, g_i convexas y h_j afines lineales, entonces si existen $\hat{x} \in C$, $(\hat{\lambda}, \hat{\mu}) \in \Lambda_0$, que satisfacen las condiciones KKT, se sigue que \hat{x} resuelve (Promix).

Dem de la condición de suficiencia:

$L(x, (\hat{\lambda}, \hat{\mu}))$ es convexa con respecto a $x \in C$, por lo que

$$L(x, (\hat{\lambda}, \hat{\mu})) \geq L(\hat{x}, (\hat{\lambda}, \hat{\mu})) + (L_x(\hat{x}, (\hat{\lambda}, \hat{\mu})))'(x - \hat{x}), \quad \forall x \in C$$

y como $-\nabla_x L(\hat{x}, \hat{\lambda}, \hat{\mu}) \in N_C(\hat{x})$ es decir $(L_x(\hat{x}, (\hat{\lambda}, \hat{\mu})))'(x - \hat{x}) \geq 0$, entonces

$$L(x, (\hat{\lambda}, \hat{\mu})) \geq L(\hat{x}, (\hat{\lambda}, \hat{\mu}))$$

y si $x \in X$ (el conjunto factible) es decir $g_i(x) \leq 0$, $h_j(x) = 0$, entonces

$L(\hat{x}, (\hat{\lambda}, \hat{\mu})) \leq f(x)$ con igualdad en \hat{x} .

Condición necesaria de optimalidad: Recuerde que si $\hat{x} \in C$ resuelve el problema (asumiendo diferenciabilidad de las funciones involucradas), entonces la condición necesaria para el (ProMix) puede expresarse como

$$-\nabla_x L(\hat{x}, \lambda, \mu) \in N_C(\hat{x}).$$

Condición suficiente de optimalidad: Si C es convexo cerrado, f, g_i convexas y h_j afines lineales, entonces si existen $\hat{x} \in C, (\hat{\lambda}, \hat{\mu}) \in \Lambda_0$, que satisfacen las condiciones KKT, se sigue que \hat{x} resuelve (Promix).

Dem de la condición de suficiencia:

$L(x, (\hat{\lambda}, \hat{\mu}))$ es convexa con respecto a $x \in C$, por lo que

$$L(x, (\hat{\lambda}, \hat{\mu})) \geq L(\hat{x}, (\hat{\lambda}, \hat{\mu})) + (L_x(\hat{x}, (\hat{\lambda}, \hat{\mu})))'(x - \hat{x}), \quad \forall x \in C$$

y como $-\nabla_x L(\hat{x}, \hat{\lambda}, \hat{\mu}) \in N_C(\hat{x})$ es decir $(L_x(\hat{x}, (\hat{\lambda}, \hat{\mu})))'(x - \hat{x}) \geq 0$, entonces

$$L(x, (\hat{\lambda}, \hat{\mu})) \geq L(\hat{x}, (\hat{\lambda}, \hat{\mu}))$$

y si $x \in X$ (el conjunto factible) es decir $g_i(x) \leq 0, h_j(x) = 0$, entonces

$L(\hat{x}, (\hat{\lambda}, \hat{\mu})) \leq f(x)$ con igualdad en \hat{x} .

En consecuencia $f(\hat{x}) \leq f(x), \forall x \in X$.

Sean f_1, \dots, f_m funciones continuamente diferenciables en \mathbb{R}^n , se define la función $f(x) := \max_{1, m} \{f_i(x)\}$ y se formula el problema

$$\min_{x \in \mathbb{R}^n} f(x) \tag{6}$$

Sean f_1, \dots, f_m funciones continuamente diferenciables en \mathbb{R}^n , se define la función $f(x) := \max_{1, m} \{f_i(x)\}$ y se formula el problema

$$\begin{array}{ll} \min & f(x) \\ & x \in \mathbb{R}^n \end{array} \quad (6)$$

Haciendo la siguiente asignación $v := \max_{1, m} \{f_i(x)\}$, entonces para cada $i = 1, \dots, m$ se cumple $f_i(x) \leq v$ y (6) se puede formular alternativamente como

$$\begin{array}{ll} \min_{x, v} & v \\ \text{s.a.} & f_i(x) - v \leq 0, \quad i = 1, \dots, m. \end{array} \quad (7)$$

Sean f_1, \dots, f_m funciones continuamente diferenciables en \mathbb{R}^n , se define la función $f(x) := \max_{1,m} \{f_i(x)\}$ y se formula el problema

$$\begin{array}{ll} \min & f(x) \\ & x \in \mathbb{R}^n \end{array} \quad (6)$$

Haciendo la siguiente asignación $v := \max_{1,m} \{f_i(x)\}$, entonces para cada $i = 1, \dots, m$ se cumple $f_i(x) \leq v$ y (6) se puede formular alternativamente como

$$\begin{array}{ll} \min_{x,v} & v \\ \text{s.a.} & f_i(x) - v \leq 0, \quad i = 1, \dots, m. \end{array} \quad (7)$$

Note que si (\hat{x}, \hat{v}) resuelve (7), entonces \hat{x} resuelve (6). Recíprocamente, si \hat{x} resuelve (6), entonces $(\hat{x}, f(\hat{x}))$ resuelve (7).

Si cada f_i es una función convexa, entonces las condiciones necesarias resultan ser condiciones suficientes.

Sean f_1, \dots, f_m funciones continuamente diferenciables en \mathbb{R}^n , se define la función $f(x) := \max_{1,m} \{f_i(x)\}$ y se formula el problema

$$\begin{aligned} & \min_{x \in \mathbb{R}^n} f(x) \end{aligned} \tag{6}$$

Haciendo la siguiente asignación $v := \max_{1,m} \{f_i(x)\}$, entonces para cada $i = 1, \dots, m$ se cumple $f_i(x) \leq v$ y (6) se puede formular alternativamente como

$$\begin{aligned} & \min_{x,v} \quad v \\ & \text{s.a.} \quad f_i(x) - v \leq 0, \quad i = 1, \dots, m. \end{aligned} \tag{7}$$

Note que si (\hat{x}, \hat{v}) resuelve (7), entonces \hat{x} resuelve (6). Recíprocamente, si \hat{x} resuelve (6), entonces $(\hat{x}, f(\hat{x}))$ resuelve (7).

Si cada f_i es una función convexa, entonces las condiciones necesarias resultan ser condiciones suficientes.

Tarea: Asumiendo que el problema tiene solución, verificar la condición de Mangasarian y así aplicar las condiciones KKT.

- Sean $X = \{2, 3\}$ y $Y = \{-1, 0, 1\}$. Se define la función L en $X \times Y$

mediante:	$x \setminus y$	-1	0	1
	2	1	2	-1
	3	4	-1	0

- Sean $X = \{2, 3\}$ y $Y = \{-1, 0, 1\}$. Se define la función L en $X \times Y$

$x \setminus y$	-1	0	1
2	1	2	-1
3	4	-1	0

$\min_x \max_y L(x, y) = 2$ y este valor se alcanza en $(x, y) = (2, 0)$.

- Sean $X = \{2, 3\}$ y $Y = \{-1, 0, 1\}$. Se define la función L en $X \times Y$

$x \setminus y$	-1	0	1
2	1	2	-1
3	4	-1	0

$\min_x \max_y L(x, y) = 2$ y este valor se alcanza en $(x, y) = (2, 0)$. Mientras que $\max_y \min_x L(x, y) = 1$ y este valor se alcanza en \dots .

- Sean $X = \{2, 3\}$ y $Y = \{-1, 0, 1\}$. Se define la función L en $X \times Y$

	$x \setminus y$	-1	0	1
mediante:	2	1	2	-1
	3	4	-1	0

$\min_x \max_y L(x, y) = 2$ y este valor se alcanza en $(x, y) = (2, 0)$. Mientras que $\max_y \min_x L(x, y) = 1$ y este valor se alcanza en \dots .

- Sean $X = Y = \mathbb{R}$ y la función $L(x, y) = x^2 - (y - 1)^2$ para todo $(x, y) \in \mathbb{R} \times \mathbb{R}$. Se cumple

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y) = 0.$$

- Sean $X = \{2, 3\}$ y $Y = \{-1, 0, 1\}$. Se define la función L en $X \times Y$

$x \backslash y$	-1	0	1
2	1	2	-1
3	4	-1	0

mediante: $\min_x \max_y L(x, y) = 2$ y este valor se alcanza en $(x, y) = (2, 0)$. Mientras que $\max_y \min_x L(x, y) = 1$ y este valor se alcanza en \dots .

- Sean $X = Y = \mathbb{R}$ y la función $L(x, y) = x^2 - (y - 1)^2$ para todo $(x, y) \in \mathbb{R} \times \mathbb{R}$. Se cumple

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y) = 0.$$

En general, para una función L definida en $X \times Y$ se cumple:

$$\min_x \max_y L(x, y) \geq \max_y \min_x L(x, y)$$

Dada una función L definida en $X \times Y$, se dice que $(\hat{x}, \hat{y}) \in X \times Y$ es un punto silla de L en $X \times Y$ si se cumple

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y) = L(\hat{x}, \hat{y})$$

Dada una función L definida en $X \times Y$, se dice que $(\hat{x}, \hat{y}) \in X \times Y$ es un punto silla de L en $X \times Y$ si se cumple

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y) = L(\hat{x}, \hat{y})$$

En un ejemplo anterior con $L(x, y) = x^2 - (y - 1)^2$ en $\mathbb{R} \times \mathbb{R}$, se tiene que $(0, 1)$ es un punto silla para L .

Dada una función L definida en $X \times Y$, se dice que $(\hat{x}, \hat{y}) \in X \times Y$ es un punto silla de L en $X \times Y$ si se cumple

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y) = L(\hat{x}, \hat{y})$$

En un ejemplo anterior con $L(x, y) = x^2 - (y - 1)^2$ en $\mathbb{R} \times \mathbb{R}$, se tiene que $(0, 1)$ es un punto silla para L .

Ejemplo:

Para $X = \mathbb{R}$, $Y = \mathbb{R}_+$, analizar la existencia de punto silla de la función $L(x, y) = x^2 - x + yx$.

Sean f, g_i, h_j funciones definidas en \mathbb{R}^n y C un conjunto cerrado de \mathbb{R}^n . Para el problema

$$\begin{array}{ll} \text{mín} & f(x) \\ (ProMix) & \text{s.a. } g_i(x) \leq 0, \ i = 1, \dots, m. \\ & h_j(x) = 0, \ j = 1, \dots, p. \\ & x \in C \end{array} \quad (8)$$

definimos la función Lagrangiana

$$L(x, \lambda, \mu) := f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x) \quad (9)$$

con $x \in C, (\lambda, \mu) \in \mathbb{R}_+^m \times \mathbb{R}^p =: \Lambda_0$.

Definimos la **función primal** asociada al problema (ProMix) como:

$$L_P(x) := \sup_{(\lambda, \mu) \in \Lambda_0} L(x, (\lambda, \mu)) , \quad x \in C \quad (10)$$

Mientras que la **función dual** asociada al problema (ProMix) se defini como

$$L_D((\lambda, \mu)) := \inf_{x \in C} L(x, (\lambda, \mu)) , \quad (\lambda, \mu) \in \Lambda_0 \quad (11)$$

Definimos la **función primal** asociada al problema (ProMix) como:

$$L_P(x) := \sup_{(\lambda, \mu) \in \Lambda_0} L(x, (\lambda, \mu)) , \quad x \in C \quad (10)$$

Mientras que la **función dual** asociada al problema (ProMix) se defini como

$$L_D((\lambda, \mu)) := \inf_{x \in C} L(x, (\lambda, \mu)) , \quad (\lambda, \mu) \in \Lambda_0 \quad (11)$$

Si en (10) el supremo resulta $+\infty$, entonces se asigna $L_P(x) = +\infty$.
Análogamente, si en (11) el ínfimo resulta $-\infty$, entonces se asigna $L_D((\lambda, \mu)) = -\infty$.

- Considere el problema

$$\begin{array}{ll} \text{mín} & x^2 + x \\ \text{s.a.} & x \leq 1 \end{array} \quad \Rightarrow \quad \begin{array}{ll} \text{mín} & x^2 + x \\ \text{s.a.} & x - 1 \leq 0 \end{array}$$

Aquí $C = \mathbb{R}$ y $\Lambda_0 = \mathbb{R}_+$; la función lagrangiana asociada es $L(x, \lambda) = x^2 + x + \lambda x - \lambda$ y

$$L_P(x) = \sup_{\lambda \geq 0} [f(x) + \lambda(x - 1)] = \begin{cases} f(x), & \text{si } x \leq 1 \\ +\infty, & \text{si } x > 1 \end{cases}$$

y

$$L_D(\lambda) = \inf_{x \in \mathbb{R}} (f(x) + \lambda x - \lambda) = -\frac{1}{4}(\lambda + 1)^2 - \lambda, \quad \lambda \geq 0.$$

- Considere el problema

$$\begin{array}{ll}
 \text{mín} & x_1^2 + 2x_2^2 - x_1 + x_2 \\
 \text{s.a.} & x_1x_2 = 1 \\
 & x_1 \geq 0, x_2 \geq 0
 \end{array}
 \quad (una\ manera) \Rightarrow \quad
 \begin{array}{ll}
 \text{mín} & x_1^2 + 2x_2^2 - x_1 + x_2 \\
 \text{s.a.} & x_1x_2 - 1 = 0 \\
 & (x_1, x_2) \in \mathbb{R}_+^2
 \end{array}$$

Aquí $C = \mathbb{R}_+^2$ y $\Lambda_0 = \mathbb{R}$; la función lagrangiana asociada es $L((x_1, x_2), \mu) = f(x_1, x_2) + \mu(x_1x_2 - 1)$ y

$$L_P(x_1, x_2) = \sup_{\mu \in \mathbb{R}} [f(x_1, x_2) + \mu(x_1x_2 - 1)] = \begin{cases} f(x), & \text{si } x_1x_2 = 1, x \in \mathbb{R}_+^2 \\ +\infty, & \text{si } x_1x_2 \neq 1, x \in \mathbb{R}_+^2 \end{cases}$$

y

$$L_D(\mu) = \inf_{x_1 \geq 0, x_2 \geq 0} (x_1^2 + 2x_2^2 - x_1 + x_2 + \mu x_1x_2 - \mu), \mu \in \mathbb{R}.$$

- Sean A una matriz de orden $m \times n$, $b \in \mathbb{R}^m$ y c un punto de \mathbb{R}^n . Considere el problema

$$\begin{array}{ll} \min & \frac{1}{2} \|x - c\|^2 \\ \text{s.a.} & Ax = b \end{array} \quad \Rightarrow \quad \begin{array}{ll} \min & \frac{1}{2} \|x - c\|^2 \\ \text{s.a.} & Ax - b = 0 \end{array}$$

Aquí $C = \mathbb{R}^n$ y $\Lambda_0 = \mathbb{R}^m$; la función lagrangiana asociada es

$$L(x, \mu) = \frac{1}{2} \|x - c\|^2 + \mu'(Ax - b) \quad \text{y}$$

$$L_P(x) = \sup_{\mu} \left[\frac{1}{2} \|x - c\|^2 + \mu'(Ax - b) \right] = \begin{cases} \frac{1}{2} \|x - c\|^2, & \text{si } Ax - b = 0 \\ +\infty, & \text{si } Ax - b \neq 0 \end{cases}$$

y

$$\begin{aligned} L_D(\mu) &= \inf_{x \in \mathbb{R}^n} \underbrace{\left(\frac{1}{2} \|x - c\|^2 + \mu'Ax - \mu'b \right)}_{G(x) \text{ convex}} \\ &= -\frac{1}{2} \|A'\mu\|^2 + \mu'(Ac - b). \end{aligned}$$

(a)

$$L_P(x) = \begin{cases} f(x), & \text{si } x \text{ es factible} \\ +\infty, & \text{en otro caso.} \end{cases}$$

(a)

$$L_P(x) = \begin{cases} f(x), & \text{si } x \text{ es factible} \\ +\infty, & \text{en otro caso.} \end{cases}$$

(b) $L_D(\lambda, \mu)$ es una función cóncava en Λ_0 .

(a)

$$L_P(x) = \begin{cases} f(x), & \text{si } x \text{ es factible} \\ +\infty, & \text{en otro caso.} \end{cases}$$

(b) $L_D(\lambda, \mu)$ es una función cóncava en Λ_0 .

(c) Asuma que para $(\lambda^*, \mu^*) \in \Lambda_0$, podemos encontrar $x^* \in C$ tal que $L_D(\lambda^*, \mu^*) = L(\lambda^*, \mu^*, x^*)$, entonces

$$L_D(\lambda, \mu) \leq L_D(\leq \lambda^*, \mu^*) + (g(x^*))'(\lambda - \lambda^*) + (h(x^*))'(\mu - \mu^*), \quad \forall (\lambda, \mu) \in \Lambda_0$$

(a)

$$L_P(x) = \begin{cases} f(x), & \text{si } x \text{ es factible} \\ +\infty, & \text{en otro caso.} \end{cases}$$

(b) $L_D(\lambda, \mu)$ es una función cóncava en Λ_0 .

(c) Asuma que para $(\lambda^*, \mu^*) \in \Lambda_0$, podemos encontrar $x^* \in C$ tal que $L_D(\lambda^*, \mu^*) = L(\lambda^*, \mu^*, x^*)$, entonces

$$L_D(\lambda, \mu) \leq L_D(\lambda^*, \mu^*) + (g(x^*))'(\lambda - \lambda^*) + (h(x^*))'(\mu - \mu^*), \quad \forall (\lambda, \mu) \in \Lambda_0$$

¿Qué papel desempeña $(g(x^*); h(x^*))$ para L_D en (λ^*, μ^*) ?

La función lagrangiana $L(x, (\lambda, \mu))$ está definida en $\Lambda = C \times \Lambda_0$ (en su respectiva versión), se sabe que siempre se cumple

$$\sup_{(\lambda, \mu)} \inf_{x \in C} L(x, (\lambda, \mu)) \leq \inf_{x \in C} \sup_{(\lambda, \mu)} L(x, (\lambda, \mu))$$

es decir

$$\sup_{(\lambda, \mu)} L_D(\lambda, \mu) \leq \inf_{x \in C} L_P(x)$$

y en el caso que estos últimos sup e ínf se alcancen, resulta que el máximo de la función dual es una cota inferior del mínimo de la función primal.

La función lagrangiana $L(x, (\lambda, \mu))$ está definida en $\Lambda = C \times \Lambda_0$ (en su respectiva versión), se sabe que siempre se cumple

$$\sup_{(\lambda, \mu)} \inf_{x \in C} L(x, (\lambda, \mu)) \leq \inf_{x \in C} \sup_{(\lambda, \mu)} L(x, (\lambda, \mu))$$

es decir

$$\sup_{(\lambda, \mu)} L_D(\lambda, \mu) \leq \inf_{x \in C} L_P(x)$$

y en el caso que estos últimos sup e ínf se alcancen, resulta que el máximo de la función dual es una cota inferior del mínimo de la función primal.

Tenga presente que en el conjunto factible X del problema (ProMix), se cumple que $L_P(x) = f(x)$ para cada $x \in X$. En consecuencia

$$\max_{(\lambda, \mu)} L_D(\lambda, \mu) \leq \text{valor óptimo del problema (ProMix)}.$$

Esta desigualdad se conoce como la condición de “Dualidad débil”

- **Problema Primal:**

$$(PP) \quad \min_{x \in C} L_P(x)$$

y supongamos que su valor óptimo es α .

- **Problema Primal:**

$$(PP) \quad \min_{x \in C} L_P(x)$$

y supongamos que su valor óptimo es α .

- **Problema Dual:**

$$(PD) \quad \max_{(\lambda, \mu) \in \Lambda_0} L_D(\lambda, \mu)$$

con valor óptimo β .

- **Problema Primal:**

$$(PP) \quad \min_{x \in C} L_P(x)$$

y supongamos que su valor óptimo es α .

- **Problema Dual:**

$$(PD) \quad \max_{(\lambda, \mu) \in \Lambda_0} L_D(\lambda, \mu)$$

con valor óptimo β .

La condición de dualidad débil, sostiene que:

$$\beta \leq \alpha = \text{Valor óptimo de (ProMix)}$$